

# Universidad de Guadalajara.

Centro Universitario de Ciencias Exactas e Ingenierías.

Ingeniería en computación.

Sección: D05.



Seminario de solución de problemas de inteligencia artificial II.

Practica 1. Ejercicio 1

Mtro. Diego Campos Peña

Montoya Vargas Roberto.

## Introducción:

En este estudio, se abordarán las cinco métricas principales utilizadas para evaluar la capacidad de una red neuronal para identificar patrones en conjuntos de datos.

## Desarrollo:

Es fundamental comprender que no todas estas métricas son adecuadas para todos los problemas, ya que cada una tiene sus propias ventajas y limitaciones, y su elección depende del tipo de resultados que se buscan obtener.

**Accuracy (precisión):** Esta métrica es especialmente útil en problemas de clasificación de datos, ya que proporciona una medida de cuán acertadamente la red neuronal ha clasificado los datos, utilizando una fórmula específica para calcular el porcentaje de aciertos.

$$\text{Precisión} = \frac{n \text{ producciones correctas}}{n \text{ producciones de instancia}}$$

Es una métrica ampliamente utilizada y fácil de interpretar, especialmente en problemas de clasificación. Sin embargo, es importante tener en cuenta que puede no ser la mejor opción cuando se trabaja con conjuntos de datos desequilibrados, donde una clase tiene muchas más instancias que otra.

**Recall (sensibilidad):** Esta métrica se centra en identificar las instancias positivas dentro de un conjunto de datos. Es especialmente útil cuando la mayoría de las instancias son negativas, ya que permite evaluar qué tan bien la red neuronal puede detectar las instancias positivas.

$$\text{Recall} = \frac{\text{verdadero positivo}}{\text{verdadero positivo} + \text{falso negativo}}$$

**Verdaderos Positivos:** Representan los casos en los que el modelo ha predicho correctamente las instancias positivas del conjunto de datos.

**Falsos Negativos:** Corresponden a los casos en los que el modelo no ha logrado identificar correctamente las instancias positivas que estaban presentes en el conjunto de datos.

Un valor de Recall cercano a 1.0 indica que el modelo está identificando eficazmente la mayoría de las instancias positivas, lo que significa que está capturando correctamente la mayor parte de la información relevante. Por otro lado, un valor bajo de Recall indica que el modelo no está capturando muchas de las instancias positivas, lo que sugiere una menor capacidad para detectar adecuadamente las características importantes del conjunto de datos.

F1-Score: Esta métrica combina las dos antes vistas y se utiliza principalmente para la evaluación con problemas de clasificación.

$$F - 1 \text{ Score} = \frac{2 \times \text{precisión} \times \text{Recall}}{\text{Precisión} + \text{Recall}}$$

Precisión: Esta métrica representa la proporción de predicciones correctas realizadas por el modelo entre el total de predicciones que clasificó como positivas.

Recall: Indica la proporción de instancias positivas que el modelo ha identificado correctamente entre el total de instancias que realmente son positivas en el conjunto de datos.

El F1-Score proporciona un balance entre precisión y recall, siendo útil cuando ambos aspectos son igualmente importantes o cuando existe un desequilibrio significativo entre las clases. Un F1-Score cercano a 1.0 sugiere un buen equilibrio entre precisión y capacidad de recuperación del modelo, mientras que un valor bajo podría indicar dificultades en al menos una de estas métricas.

Precisión por clase: Esta métrica extiende el concepto de precisión al contexto de problemas de clasificación multiclase. Evalúa la precisión de la clasificación para cada clase por separado, lo que proporciona información detallada sobre el rendimiento del modelo en cada categoría específica.

$$\text{Precisión por clase}_i = \frac{\text{verdadero positivo}_i}{\text{verdadero positivo}_i + \text{falso positivo}_i}$$

La Matriz de Confusión es una herramienta esencial para evaluar el rendimiento de una red neuronal en problemas de clasificación. Esta matriz desglosa el número de predicciones correctas e incorrectas en cuatro categorías distintas:

Verdaderos Positivos (True Positives - TP): Representan las instancias positivas que fueron correctamente identificadas como tales por el modelo.

Verdaderos Negativos (True Negatives - TN): Son las instancias negativas que fueron correctamente identificadas como negativas por el modelo.

Falsos Positivos (False Positives - FP): Corresponden a las instancias negativas que fueron incorrectamente clasificadas como positivas por el modelo.

Falsos Negativos (False Negatives - FN): Son las instancias positivas que fueron incorrectamente clasificadas como negativas por el modelo.

### **Conclusión:**

Esta actividad me proporcionó una comprensión más profunda sobre cómo manejar y evaluar los resultados de una red neuronal de manera más coherente. Pude observar la importancia de elegir las métricas de evaluación adecuadas según las características específicas de nuestro proyecto. Noté que no todas las métricas son aplicables a cualquier tipo de red neuronal, por lo que es crucial comprender las necesidades y los objetivos del proyecto para seleccionar las métricas que nos ayudarán a obtener los mejores resultados posibles.

### **Bibliografía:**

- datos.gob.es. (2021, January 26). ¿Cómo sé si mi modelo de predicción es realmente bueno? datos.gob.es.

<https://datos.gob.es/es/blog/como-se-si-mi-modelo-de-prediccion-es-realmente-bueno>

- Izaurieta, F., & Saavedra, C. (2000). Redes neuronales artificiales. Departamento de Física, Universidad de Concepción Chile.